

**La accesibilidad de la vivienda para los jóvenes (18-34) en el Reino Unido: salario, esfuerzo
hipotecario y clima (2015-2020)**

Juan Pablo Angel Quitian, Joel Sebastian Bueno Medina

Corporacion Universitaria Minuto de Dios (UNIMINUTO), Ibague

Curso: Minería de Datos

Docente: Esteban Ernesto Morales Castro

septiembre de 2026

Contenido

Resumen.....	5
Introduccion	6
Fases del proyecto y estado del avance.....	6
Planteamiento del problema y pregunta de investigacion.....	7
Justificacion	7
Objetivos	8
Objetivo general.....	8
Objetivos especificos	8
Hipotesis	8
Metodologia	9
Marco metodologico: KDD, CRISP-DM y SEMMA.....	9
Por que se eligieron KDD y CRISP-DM	10
Como se aplico al proyecto y que resultado dio cada fase	10
Lo que llevamos del avance.....	11
Conceptos usados.....	12
Fuentes de datos	12
Columnas utilizadas por fuente.....	13
Limpieza y calidad de datos.....	14
Datos faltantes: MCAR, MAR y MNAR.....	14

Atipicos: IQR (Tukey) frente a z-score	15
Construccion del cuadro maestro y calculos.....	16
Implementacion tecnica (codigo).....	17
Buenas practicas de ingenieria de software y documentacion.....	19
Criterios de calidad (rubrica de codigo del curso)	20
Desarrollo por fases	21
Fase 1: introduccion y objetivos	21
En que consiste	21
Contexto y en que punto lo llevamos.....	21
Que se hizo y por que.....	21
Resultado.....	21
Fase 2: fuentes y tipos de datos.....	22
En que consiste	22
Contexto y en que punto lo llevamos.....	22
Que se hizo y por que.....	22
Resultado.....	23
Fase 3: limpieza y cruzamiento (avance actual)	23
En que consiste	23
Contexto y en que punto lo llevamos.....	23
Que se hizo y por que.....	24

Resultado.....	24
Fase 4: analisis y modelado (pendiente)	24
En que consiste	24
Contexto y en que punto lo llevamos.....	24
Que se hara y por que.....	25
Resultado esperado	25
Resultados	25
Anos de salario joven para comprar.....	25
Esfuerzo hipotecario 2022	26
Clima y precios	27
Discusion y limitaciones	28
Trabajo futuro (fase 4)	28
Referencias.....	29

Resumen

Este avance estima cuanto puede pagar un joven (18-34) por la vivienda mediana de su region en el Reino Unido: con su salario, con hipoteca y contemplando el clima. Se cruzan cuatro fuentes (transacciones de compra-venta, oferta hipotecaria 2022, series climaticas Met Office y precios/salarios nacionales) dentro del ciclo KDD y CRISP-DM. En la fase 3 los datos se depuraron: se detectaron duplicados, se clasificaron los faltantes (MCAR, MAR o MNAR) con su evidencia y se decidio el tratamiento de atipicos (IQR frente a z-score), para terminar de construir el cuadro maestro anio-region 2015-2020. El salario joven quedo en GBP 25.353 anuales; comprar la vivienda mediana exige entre 6,2 anos de salario (North East) y 14,2 (London). Con la oferta hipotecaria de 2022 (tasa inicial media winsorizada de 6,04 %), la cuota mensual consume entre el 43,0 % y el 100,0 % del ingreso, asi que ninguna region cumple el umbral del 30 %. Finalmente, la asociacion clima-precios resulto debil y negativa ($|r| < 0,4$). Se concluye que la baja accesibilidad la explican el salario y las hipotecas, con un efecto marginal del clima, y el avance deja un cuadro maestro verificado y reproducible.

Palabras clave: accesibilidad de vivienda; jovenes; Reino Unido; hipoteca; salario; mineria de datos; CRISP-DM.

Introduccion

En el Reino Unido los jovenes de 18 a 34 anos forman hoy una generacion que compra cada vez menos vivienda propia. La razon visible es que la compra junta tres exigencias dificiles de cumplir: tener un ahorro inicial, contar con un salario que lo soporte y sostener una hipoteca; y los precios han crecido por encima de los salarios al tiempo que las tasas encarecieron la cuota mensual. Este trabajo, en la fase 3 del ciclo KDD/CRISP-DM, depura y cruza cuatro fuentes para responder una pregunta concreta: cuanta vivienda puede pagar un joven en su region con su salario, cuan costosa le resulta con credito hipotecario y si el clima tiene algo que ver con la evolucion de los precios.

Fases del proyecto y estado del avance

El proyecto replica el ciclo del curso (caso TelecomUNO) en cuatro fases consecutivas, tal como las define la guia: fase 1 de introduccion y objetivos, fase 2 de fuentes y tipos de datos, fase 3 de limpieza y cruzamiento y fase 4 de analisis y modelado. Cada fase deja un entregable y se documenta con su que, su porque y su resultado. La tabla 1 resume este plan y su estado; el presente avance corresponde a la fase 3, en curso.

Las fases 1 y 2 estan completas: fijaron la pregunta, los objetivos y las hipotesis (fase 1) y dejaron cargadas y tipadas las fuentes con sus volumenes y columnas (fase 2). La fase 3 es el entregable de hoy: depurar cada fuente, clasificar los datos faltantes, decidir el tratamiento de los atipicos y construir el cuadro maestro anio x region con los primeros indicadores de accesibilidad. La fase 4 queda pendiente y modelara las series regionales para pronosticar la evolucion de los precios.

Tabla 1

Fase	KDD	CRISP-DM	Estado
1. Introduccion y objetivos	Seleccion	Entendimiento del negocio	Completada
2. Fuentes y tipos de datos	Seleccion y preprocesamiento I	Entendimiento de los datos	Completada
3. Limpieza y cruzamiento	Preprocesamiento II	Preparacion de los datos	En curso
4. (futura) Analisis y modelado	Mineria	Modelado	Pendiente

Nota. Estado al corte de septiembre de 2026.

Planteamiento del problema y pregunta de investigacion

El problema de fondo es la brecha que crece entre el precio de la vivienda y el ingreso de los jovenes, agravada por un mercado de credito que encarece la entrada. La pregunta que guia el proyecto es: que relacion existe entre el salario joven, el esfuerzo hipotecario y la evolucion de los precios por region entre 2015 y 2020, y que papel juega el clima en esa evolucion?

Justificacion

El tema importa social y economicamente: la vivienda es un bien de primera necesidad y su costo define donde y como puede vivir la poblacion joven, su independencia, su movilidad laboral y la formacion de hogares. Documentar con datos que tan lejos queda la compra para ese grupo aporta evidencia util tanto para los compradores (planificar o descartar la compra) como para los prestamistas y las politicas publicas de acceso a vivienda. Desde el punto de vista metodologico, el proyecto aplica de forma integrada el ciclo KDD y CRISP-DM sobre cuatro

fuentes reales, dejando reproducible cada decision de depuracion, lo que sirve como ejercicio completo de mineria de datos: se toma, se limpia, se cruza y se interpreta.

Objetivos

Objetivo general

Analizar la accesibilidad de la vivienda para jovenes (18-34) por region del Reino Unido mediante el cruce de transacciones, oferta hipotecaria, series climaticas y precios/salarios, aplicando el ciclo KDD y CRISP-DM con entregables por fase.

Objetivos especificos

Consolidar el cuadro maestro anio x region con calidad verificable (duplicados, tipos, faltantes y atipicos).

Regionalizar el salario joven a partir de la mediana nacional y la brecha salarial por edad de 2021.

Estimar el esfuerzo hipotecario de un joven por region en el corte 2022 y compararlo con el umbral del 30 % del salario.

Medir la asociacion entre la variacion anual de precios y las anomalias climaticas frente a la normal historica 1931-2020.

Comunicar los resultados con cuadernos reproducibles, figuras e informes.

Hipotesis

H1: en ninguna region el esfuerzo hipotecario de un joven sobre la vivienda mediana de 2022 cumple el umbral del 30 % del salario. H2: las regiones del norte y Gales requieren menos anos de salario joven que London y el sur de Inglaterra. H3: las anomalias climaticas se asocian de forma debil y negativa con la variacion anual del precio.

Metodologia

Esta seccion desarrolla la fase 3 en detalle: los conceptos usados, las fuentes y sus columnas, el proceso de limpieza, la construccion del cuadro maestro y la implementacion tecnica que hace reproducible cada paso. El plan de fases ya se presento en la tabla 1.

Marco metodologico: KDD, CRISP-DM y SEMMA

El panorama metodologico del curso presenta tres marcos para un proyecto de mineria de datos: KDD, CRISP-DM y SEMMA (tabla 2). El curso sigue CRISP-DM y este proyecto integra dos marcos de forma combinada: el ciclo KDD por su claridad conceptual del proceso de descubrimiento, y CRISP-DM porque arranca en el problema de negocio, es iterativo y es la metodologia mas adoptada en la industria. SEMMA se descarta por parcial y ligada a SAS.

Tabla 2

Aspecto	KDD	CRISP-DM	SEMMA
Origen	Academico (Fayyad et al., 1996)	Consortio industrial (SPSS, Daimler, 1999)	Fabricante SAS
Etapas	Seleccion, preprocesamiento, transformacion, mineria, interpretacion	Negocio, datos, preparacion, modelado, evaluacion, despliegue	Sample, Explore, Modify, Model, Assess
Fortaleza	Claridad conceptual del proceso completo	Arranca en el negocio, es iterativa y la mas usada (~85 %)	Simple y ligada a la herramienta

Debilidad	Omite el negocio y el despliegue	Exige disciplina documental	Parcial y sesgada a SAS
-----------	----------------------------------	-----------------------------	-------------------------

Nota. Adaptado de la sesion 1 del curso (panorama de metodologias).

Por que se eligieron KDD y CRISP-DM

La eleccion no fue un marco, sino dos, y por tres razones que se verifican en los resultados. Primera, cobertura del ciclo completo: un proceso KDD descrito originalmente por Fayyad et al. (1996) cubre el descubrimiento (seleccion, preprocesamiento, transformacion, mineria, interpretacion), mientras que CRISP-DM (Wirth & Hipp, 2000) lo enmarca en el negocio (entendimiento, datos, preparacion, modelado, evaluacion, despliegue); usar solo uno deja un hueco, KDD sin despliegue y CRISP-DM sin el detalle conceptual de las etapas teoricas. Segunda, coincidencia con el curso: la sesion 1 confirma que la asignatura se enruta por CRISP-DM y pide el Avance 1 como entrega de las tres primeras fases (negocio, datos y preparacion), que es exactamente lo que este documento reporta. Tercera, trazabilidad: al declarar la equivalencia por fase (tabla 1), cada decision se puede rastrear hasta su etapa KDD y su fase CRISP-DM, que es una buena practica de documentacion. SEMMA se dejo fuera porque es parcial (se queda en la parte analitica) y esta atado a la herramienta SAS, lo que lo hace poco transferible a un entorno Python.

Como se aplico al proyecto y que resultado dio cada fase

La aplicacion siguio el orden del curso: en la fase 1 se fijaron la pregunta, los objetivos y las hipotesis (entendimiento del negocio); en la fase 2 se identificaron las fuentes, su estructura y sus tipos (entendimiento de los datos); y la fase 3, el avance actual, materializa la preparacion de los datos con el orden deduplicar, categorias, nulos MCAR/MAR/MNAR, atipicos IQR, cruce e indicadores. La principal evidencia de la eleccion es que las promesas del marco se cumplen con

numeros: se partio de 11.369.413 transacciones y 7.796 productos de hipoteca, se depuraron 37.029 registros climaticos, se clasificaron los faltantes en las tres tipologias, se winsorizo la tasa inicial (media de 6,11 % a 6,04 %), se cruzo un cuadro maestro de 60 filas sin huecos y se estimo el esfuerzo de 2022 (43,0 % en North East frente a 100,0 % en London). Sin un marco que ordenara el trabajo, esas decisiones no tendrian donde apoyarse.

```
# Como se materializan las fases en el codigo (script/proyecto/)
# Fases 1-2 (completas) -> config.py (rutas y reglas) y cargar.py (origenes)
# Fase 3 (avance actual) -> limpiar.py -> diagnostico.py -> transformaciones.py
#                               -> cruces.py -> indicadores.py -> validacion.py
# Fase 4 (pendiente)      -> modelado de las series por region

# Ejemplo completo y legible: esfuerzo hipotecario del corte 2022
tasa_media = hipotecas["tasa_inicial_pct"].mean() # 6,04 % ya winsorizada
(F2)
cuota_mensual = cuota_mensual_pmt(precio_real_2020, tasa_media,
                                  PLAZO_ANIOS, LTV, comisiones) # formula
francesa
esfuerzo = cuota_mensual / salario_joven_mensual # % del salario que se va
en la hipoteca
accesible = esfuerzo <= UMBRAL_ACCESIBILIDAD # accesible si 30 % o
menos
```

Lo que llevamos del avance

El corte actual deja un estado acumulado que se resume en los entregables que ya existen y se pueden verificar: (1) cinco cuadernos ejecutados de extremo a extremo, uno por etapa de la fase; (2) un paquete de once modulos Python que orchestra el pipeline completo; (3) un cuadro maestro maestro_joven_uk con la mediana del precio, el salario joven regionalizado y las anomalias climaticas por anio y region; (4) una bitacora de decisiones que registra que se cambio, cuantos valores y con que criterio; (5) once figuras en md/figuras y tres informes (propuesta metodologica, informe del avance 1 y este documento APA). Queda pendiente la fase 4 (analisis y modelado), que modelara las series regionales para proyectar el esfuerzo futuro y, al cerrar, permitira evaluar el ciclo contra el objetivo de negocio.

Conceptos usados

Para leer el informe conviene tener presentes cinco definiciones. Salario joven: la mediana de ingresos de las personas de 18 a 34 años, estimada a partir de la mediana nacional y la brecha salarial por edad de 2021 (GBP 25.353 anuales). Años de salario: cuantas veces el salario anual compra la vivienda mediana de la región (regla prudente de banca: menos de 4). Esfuerzo hipotecario: porcentaje del salario mensual que consume la cuota; el umbral saludable es 30 %. LTV (loan to value): proporción del valor que se financia (aquí 90 %). Anomalia climática: cuanto se desvía una variable mensual de su normal histórica 1931-2020.

Fuentes de datos

Se usan cuatro fuentes (tabla 3). F1 proviene del registro de ventas del Land Registry geocodificado (11.369.413 transacciones); F2 es un snapshot de oferta hipotecaria de 2022; F3 reúne 36 estaciones meteorológicas mensuales y F4 combina la serie nacional de precios y salarios con la brecha salarial por edad de 2021. La ventana de cruce completo es 2015-2020 y el corte hipotecario se analiza para 2022.

Tabla 3

Fuente	Descripción	Filas	Periodo
F1	Transacciones (Land Registry + geo)	11.369.413	2015-2026
F2	Oferta hipotecaria (Kaggle, snapshot)	7.796	2022
F3	Estaciones Met Office (36)	37.049	1931-2020
F4	Precio medio +	46	1975-2020

salario mediana			
F4b	Salario por edad y	12	2021
genero			

Nota. F4b aporta la mediana salarial por banda de edad y genero.

Columnas utilizadas por fuente

De cada archivo se leen solo las columnas necesarias (tabla 4): F1 aporta la fecha, el precio y la region ya geocodificada del registro de ventas; F2 el tipo de producto, la tasa inicial, la tasa de reversion y las comisiones; F3 la serie mensual completa de las cinco variables climaticas; y F4 las series nacionales de precio y salario junto con la mediana por banda de edad. El fragmento del modulo cargar.py muestra esa seleccion y el paso que convierte las transacciones en la mediana anual por region:

Tabla 4

CSV / modulo	Columnas leidas	Para que se usan
F1 ventas (Land Registry)	transaction_id, price, date_of_transfer, region	Anio, mediana regional del precio y conteo de transacciones
F2 hipotecas (2022)	tipo, tasa_inicial_pct, tasa_reversion, comisiones_total	Duplicados, clase MAR, atipicos IQR y cuota PMT
F3 clima Met Office	estacion, anio, mes, tmax, tmin, af, lluvia, sol	Serie mensual, faltantes MCAR/MNAR y anomalias
F4 precios y salario	anio, precio_promedio_real, salario_mediana_real	Serie nacional 1975-2020 y salario joven 2020

F4b salario por edad	grupo_edad, genero,	Brecha salarial por edad
	salario_mediana	(factor 0,805)

Nota. Detalle completo de rutas en script/proyecto/config.py.

```
# F4a: seleccion de columnas - script/proyecto/cargar.py
df = df[["Year",
        "Average house price adj. by inflation (pounds)",
        "Median Salary adj. by inflation (pounds)"]].copy()
df.columns = ["anio", "precio_promedio_real", "salario_mediana_real"]

# F1 (parquet ya limpio con region): mediana por anio x region
g = df[df["year"] >= config.ANIO_MIN_PRECIOS].groupby(
    ["year", "region"], observed=True).agg(
    n_transacciones=("price", "size"),
    precio_mediana=("price", "median"))
```

Limpieza y calidad de datos

En la fase 3 se depuro cada fuente en el orden del curso: duplicados, contratos de tipos, datos faltantes y atipicos. No se detectaron duplicados relevantes (claves naturales de producto y de estacion-mes); los simbolos de la Met Office (---, *, #) se convirtieron en valores perdidos numericos y las filas sin fecha del clima (20) se eliminaron por no ser mediciones.

Datos faltantes: MCAR, MAR y MNAR

Cada variable faltante se clasifico con evidencia (tabla 5) siguiendo la tipologia clasica de Little y Rubin (2019): MCAR si la ausencia no depende de nada medible, MAR si depende de otra variable observada y MNAR si depende del propio valor o del diseno de la fuente. La tasa de reversion de las hipotecas es MAR (depende del tipo de producto: de 0,8 % en fijo a 39,5 % en tasa variable); las temperaturas y lluvias son MCAR instrumental (falla conjunta de reporte: en 1.467 de 1.599 meses falta tmax y tmin a la vez) y el sol, junto con el salario historico, son MNAR estructural (no publicados antes de 1931 y de 1999, respectivamente). Los valores perdidos no se imputan en esta fase.

Tabla 5

Fuente	Variable	Nulos	Clase	Tratamiento
F2	tasa_reversion	328 (4,2 %)	MAR	Depende del tipo observado; se conserva NaN
F3	anio/month	20 (0,05 %)	MNAR	Registro corrupto (sin fecha); se elimina
F3	tmax / tmin	1.599 / 1.522	MCAR	Falla conjunta de reporte; NaN
F3	af / lluvia	2.949 / 1.478	MCAR	Falla conjunta de reporte; NaN
F3	sol	9.483 (25,6 %)	MNAR estructural	No publicada antes de 1931; NaN
F4	salario_mediana_real	24 (52,2 %)	MNAR estructural	No publicada antes de 1999; NaN

Nota. Clasificación generada con evidencia reproducible en `script/proyecto/diagnostico.py`.

Atípicos: IQR (Tukey) frente a z-score

Sobre la tasa inicial de las hipotecas (que alimenta la cuota) se compararon los dos métodos (tabla 6): la regla del intervalo de Tukey ($Q1 - 1,5 \text{ IQR}$, $Q3 + 1,5 \text{ IQR}$), que la literatura

de preprocesamiento recomienda por su robustez a la distribución (Han et al., 2012), detecta 762 productos (9,77 %) por encima del límite superior (8,13 %), mientras que el z-score con $|z| > 3$ no detecta ninguno, por asumir normalidad. Por su robustez, se decidió el método IQR y se winsorizo la tasa en su límite (la media pasa de 6,11 % a 6,04 %) sin eliminar filas y con una bandera de atípico.

Tabla 6

Metodo	Criterio	Detectados	Observacion
IQR (Tukey)	Fuera de [Q1 - 1,5 IQR, Q3 + 1,5 IQR]	762 (9,77 %)	No exige normalidad
z-score	$ z > 3$	0 (0 %)	Asume normalidad

Nota. Datos: 7.796 productos hipotecarios de 2022; Q1 = 5,62, mediana = 6,10, Q3 = 6,62, IQR = 1,00.

Construcción del cuadro maestro y cálculos

El salario joven se estimó como la media de las medianas de las bandas 18-21, 22-29 y 30-39 (GBP 25.353 al año, factor 0,805 sobre la mediana nacional 2020) y se regionalizó con factores de referencia de la encuesta de horas y ganancias del Reino Unido (Office for National Statistics, 2022). El cuadro maestro_joven_uk cruza, para 10 regiones y 6 años (2015-2020), el precio mediano de F1, el salario joven regionalizado y las anomalías climáticas frente a la normal 1931-2020. La cuota hipotecaria se calcula con la fórmula PMT sobre el 90 % del valor, 25 años y la tasa inicial media winsorizada; el precio de 2022 se deflacta a GBP-2020 (CPI del Banco de Inglaterra, factor 1,137).

Implementacion tecnica (codigo)

Todo el proceso se implemento en Python (pandas, numpy y matplotlib) como un paquete modular, no como scripts sueltos: cada etapa vive en un modulo con una responsabilidad clara (tabla 7), lo que facilita revisar, reutilizar y probar cada parte por separado.

Tabla 7

Modulo	Responsabilidad
config.py	Rutas, reglas, factores regionales y estaciones
cargar.py	Carga defensiva de las 4 fuentes con dtypes
limpiar.py	Depuracion por fuente: duplicados, tipos, nulos
diagnostico.py	Faltantes MCAR/MAR/MNAR e IQR vs z-score
transformaciones.py	Agregados, anomalias climaticas y salario joven
cruces.py	Cuadro maestro anio x region
indicadores.py	Anos de salario, cuota PMT y correlaciones
graficos.py	Figuras PNG para el informe
validacion.py	Verificaciones post-cruce (asserts)
bitacora.py	Bitacora Markdown de decisiones
pipeline.py	Orquesta el proceso en 11 partes

Nota. Paquete script/proyecto; el orquestador es pipeline.py.

El flujo se organiza como un pipeline de 11 pasos que reproducen el orden del curso, y cada paso se imprime en consola para seguirlo: origen de los datos, limpieza por fuente,

clasificación de faltantes (MCAR/MAR/MNAR), tratamiento de atípicos (IQR frente a z-score), transformaciones, cruce, indicadores, análisis clima-precio, validación, exportación y bitácora final de decisiones.

1. Orígenes intocables: carga las 5 rutas y copias crudas.
2. Limpieza por fuente: duplicados, tipos y nulos.
3. Faltantes: clasificación MCAR/MAR/MNAR con evidencia y figura.
4. Outliers: IQR vs z-score, winsorización y bandera es_atípico_tasa.
5. Transformaciones: agregados por región/ciudad, anomalías y salario joven.
6. Cruce: maestro_joven_uk (año x región, 2015-2020).
7. Indicadores: años de salario y esfuerzo hipotecario 2022.
8. Análisis clima vs precios (correlación de Pearson).
9. Validación post-cruce con asserts.
10. Exportar parquets, CSVs muestra, figuras y bitácora.
11. Tabla final de la bitácora de decisiones.

A modo de ilustración, el fragmento del cuaderno 02 muestra cómo se winsoriza la tasa inicial y cómo queda la cuota mensual del cuaderno 04:

```
# Winsorización IQR de la tasa inicial (F2) - pipeline paso 4 / cuaderno 02
tasa = self.hipotecas["tasa_inicial_pct"]
limite = diagnostico.limite_iqr(tasa)["limite_superior"] # 8,13 según Tukey
self.hipotecas["tasa_inicial_pct"] = diagnostico.winsorizar(tasa, limite)
self.hipotecas["es_atípico_tasa"] = tasa > limite

# Cuota mensual (PMT): 90 % LTV, 25 años - cuaderno 04 / indicadores.py
cuota = cuota_mensual_pmt(precio_real_2020, tasa_media, PLAZO_ANIOS, LTV,
comisiones)
esfuerzo = cuota / salario_joven_mensual # umbral: 30 %
```

La reproducibilidad se apoya en cuatro piezas: el archivo principal (main_proyecto.py) que corre el pipeline completo; los cinco cuadernos ejecutados de extremo a extremo que

documentan y grafican cada etapa; la bitacora Markdown que deja constancia de cada decision; y las rutas centralizadas en config.py con origenes guardados en data/crudo y resultados en data/integrado y md/figuras.

Buenas practicas de ingenieria de software y documentacion

Para que un analisis de datos pase de ser un archivo suelto a un proyecto profesional se aplicaron practicas de ingenieria de software que facilitan revisar, reutilizar y repetir el trabajo:

- Modularidad: un paquete (script/proyecto) con un modulo por responsabilidad (config, cargar, limpiar, diagnostico, transformaciones, cruces, indicadores, graficos, validacion, bitacora y pipeline); cada funcion hace una sola cosa y se puede probar por separado.

- Configuracion centralizada: config.py concentra rutas, ventanas de anos, factores regionales, LTV, plazo, umbrales y nombres de archivo; en el codigo no hay constantes magicas.

- Origenes intocables: las fuentes crudas nunca se modifican; cada transformacion escribe en data/limpia o data/integrado y en el repositorio solo se versionan muestras (_muestra) para no subir gigabytes.

- Reproducibilidad: un solo comando (python main_proyecto.py) corre el proceso completo, los cuadernos corren de principio a fin sin cambios y requirements.txt declara el entorno.

- Validacion automatica: el pipeline verifica filas, claves, nulos y rangos antes de exportar (validacion.py) y se detiene si algo no cumple.

- Bitacora de decisiones: md/BITACORA_DECISIONES.md registra que se cambio, cuantas filas afecto, como y por que, tal como pide la guia.

- Documentacion en capas: docstrings y comentarios en el codigo (que y por que), celdas markdown en los cuadernos, notas bajo cada tabla, y tres informes para distintas audiencias (propuesta, informe del avance 1 y este documento APA).

- Control de versiones: git con .gitignore (entorno, caches y datos grandes) y un commit por corte que deja el repositorio siempre listo para reproducir.

El codigo siguiente muestra las dos practicas mas visibles: validar antes de exportar y dejar cada decision anotada en la bitacora.

```
# validacion.py: el pipeline no deja pasar datos incorrectos
validar_maestro(cuadro)          # asserts de filas, clave, nulos y rangos
assert cuadro[["anio", "region"]].duplicated().sum() == 0    # clave anio+region
                           unica
assert not cuadro[["precio_mediana",
"salario_joven_region"]].isna().any().any()
assert (cuadro["precio_mediana"] > 0).all()                  # precios positivos

# bitacora.py: cada decision queda documentada (que, cuanto, metodo y por que)
bitacora.anotar("F2 hipotecas", "tasa inicial atipica", cantidad=762,
                metodo="winsorizar con limites IQR (Tukey)",
                razon="IQR detecta 762 atipicos y z-score 0; no asume
normalidad")
```

Criterios de calidad (rubrica de codigo del curso)

La guia evalua todo entregable programado con cuatro criterios y este avance se revisa contra ellos: funcionalidad (el pipeline ejecuta de principio a fin y valida filas, nulos y rangos contra criterios explicitos), justificacion tecnica (cada decision se defiende con evidencias: MCAR/MAR/MNAR, IQR frente a z-score y el contexto de negocio de cada fuente), documentacion (celdas markdown y comentarios que explican que hace y por que cada bloque, mas hallazgos en texto legible) y reproducibilidad (rutas centralizadas, origenes intocables, semillas fijas y cuadernos que corren sin cambios).

Desarrollo por fases

Cada fase de la guía (tabla 1) se explica con su contexto, en que punto lo llevamos, que se hizo y por que, y el resultado que dejó. Así se puede seguir el hilo completo: entender por que existe la fase, ver el estado del avance, revisar el trabajo y comprobar la cifra con la que cerró.

Fase 1: introducción y objetivos

En que consiste

Consiste en delimitar el problema y fijar que se quiere responder: la pregunta de investigación, la justificación, los objetivos general y específicos y las hipótesis que orientan todo el análisis.

Contexto y en que punto lo llevamos

Corresponde a la fase de entender el negocio (CRISP-DM) y a la selección del problema (KDD). Sigue el caso del curso: primero se define que se quiere saber y para quien, y solo después se tocan datos. Esta fase está completada: la pregunta, los objetivos y las hipótesis quedaron fijados y no han cambiado durante el avance.

Que se hizo y por que

Se delimitó el tema (la accesibilidad de la vivienda para los jóvenes de 18 a 34 en el Reino Unido), se formuló la pregunta, la justificación, los objetivos y las hipótesis, y se definieron los ciclos KDD y CRISP-DM como método. Se hizo así porque un análisis de datos necesita preguntas claras antes de tocar ningún dato: si no se sabe que se busca, no se sabe que limpiar ni que cruzar.

Resultado

Las secciones de introducción, planteamiento, justificación, objetivos e hipótesis de este documento (identificación de la fase 1) y la pregunta de investigación que guía el avance.

Fase 2: fuentes y tipos de datos

En que consiste

Consiste en localizar y describir las fuentes: cuantos registros y columnas tiene cada una, de que periodo habla, en que estructura esta guardada y que tipos de dato maneja, dejandolas fijadas como origenes intocables para que el proyecto sea reproducible.

Contexto y en que punto lo llevamos

Corresponde a la sesion 2 de la guia (fuentes y tipos de datos), que es la etapa de seleccion del KDD y de entendimiento de los datos del CRISP-DM. El contexto concreto del proyecto es dispar: F1 llega en parquet ya limpio de una fase anterior, F2, F3 y F4 llegan en CSV con convenciones distintas (snapshot 2022, series mensuales de estaciones y serie nacional anual) y F4b es la brecha salarial por edad. Por eso esta fase consistio en igualar el terreno: verificar los tipos que pandas infiere al cargar, detectar si una columna numerica cayo como texto y fijar la ventana de anos en la que las series se pueden cruzar sin inventar periodos. Esta fase esta completada: las cinco fichas quedan localizadas, tipadas y con volumen conocido.

Que se hizo y por que

Se localizaron las cinco fichas (las cuatro fuentes mas la brecha salarial por edad), se definieron rutas y tipos de dato en config.py y cada fuente se cargo con una lectura defensiva que cuenta filas y columnas antes de seguir (pandas carga, pero quien decide si cargo bien son los types que reporta). Se hizo asi porque comprender el dominio y conservar los origenes intactos permite repetir cualquier resultado desde cero, y porque la sesion 1 del curso pide origenes intocables: nada se edita a mano sobre el CSV crudo.

Resultado

La tabla 3 resume los volúmenes (F1 con 11.369.413 transacciones, F2 con 7.796 productos, F3 con 37.049 registros, F4 con 46 años y F4b con la mediana por edad), la tabla 4 detalla las columnas que se usan de cada archivo y las cargas quedan documentadas en el cuaderno 01. Con esto se dispuso del punto de partida: las fuentes listas para ser limpiadas en la fase 3.

Fase 3: limpieza y cruzamiento (avance actual)

En que consiste

Es la fase que deja los datos listos para el análisis: depurar cada fuente, clasificar los datos faltantes, decidir con evidencia que hacer con los atípicos, cruzar las fuentes en un cuadro maestro año x región y estimar los primeros indicadores de accesibilidad. En la guía corresponde a la sesión 3 (limpieza de datos) y materializa la preparación de los datos del CRISP-DM y el preprocesamiento del KDD.

Contexto y en que punto lo llevamos

Esta es la fase que se entrega ahora, por eso es el corazón del informe. Su contexto es que las cuatro fuentes llegan con problemas reales y distintos: símbolos de la Met Office que se disfrazan de números, tasas de reversion ausentes que dependen del tipo de producto, horas de sol y salario histórico que simplemente no se publicaban antes de cierta fecha, y una tasa inicial con una cola de productos caros. Nada de eso se puede imputar ni borrar a la ligas; hay que clasificarlo. En que punto lo llevamos: las fases 1 y 2 están completas y esta fase está en curso, pero con sus entregables cerrados (cuadro maestro, indicadores, figuras y bitácora); lo único que falta del ciclo es la fase 4 de modelado, que usa este cuadro como entrada.

Que se hizo y por que

Se siguió el orden del curso (deduplicar, categorías, nulos, atípicos): se revisaron duplicados, tipos, valores inválidos y fechas (los símbolos de la Met Office pasaron a perdidos); se clasificaron los faltantes MCAR/MAR/MNAR (tabla 5); se compararon IQR y z-score para la tasa de las hipotecas (tabla 6); se winsorizó la tasa y se construyó el cuadro maestro con el salario joven regionalizado. Se hizo así porque las decisiones sobre nulos y extremos no se improvisan: clasificar permite saber si la ausencia es azar, dependencia o diseño, y comparar los dos métodos justifica por qué gana la winsorización. Además, como pide la guía, cada decisión quedó en la bitácora y se validó el resultado con asserts antes de exportar.

Resultado

37.029 registros de clima válidos (20 filas sin fecha descartadas), una tasa inicial winsorizada en 6,04 %, un mapa de faltantes sin imputar datos, un cuadro maestro de 60 filas sin huecos, un salario joven de GBP 25.353 (factor 0,805 sobre la mediana nacional) y los indicadores que se presentan en la sección de resultados: ninguna región cumple el umbral del 30 % y el norte sigue siendo más accesible que London.

Fase 4: análisis y modelado (pendiente)

En que consiste

Consistirá en modelar las series regionales de precio y salario para pronosticar la evolución de la accesibilidad y del esfuerzo hipotecario, cerrando el ciclo con un modelo que proyecte, no solo describa, el problema.

Contexto y en que punto lo llevamos

Corresponde al avance 2 del curso (sesiones 7 a 11), donde la guía pasa de la preparación al modelado: clasificación, regresión y series. El contexto del proyecto es favorable porque esta

fase no parte de cero: el cuadro maestro de 60 filas que dejo la fase 3 ya tiene, por año y región, el precio mediano, el salario joven regionalizado y las anomalías climáticas, es decir, la tabla lista para ajustar modelos. En que punto lo llevamos: pendiente; no se ha iniciado y por eso este informe no reporta pronósticos todavía.

Que se hara y por que

Se ajustará un modelo interpretable sobre las medianas anuales por región, se validará contra el período histórico y se proyectará el esfuerzo futuro. Se hace porque el ciclo KDD termina en un modelo que sostiene las decisiones, y el informe debe mostrar ese resultado (fases de minería/modelado de las tablas KDD y CRISP-DM).

Resultado esperado

Proyecciones por región, su comparación con el umbral del 30 % del salario y la actualización de este informe con los resultados de la fase 4.

Resultados

Años de salario joven para comprar

La tabla 8 ordena las regiones por los años completos de salario joven necesarios para comprar la vivienda mediana (promedio 2015-2020). London casi duplica al north East (14,2 frente a 6,2 años) y ninguna región cumple la regla prudente de banca de 4 años: se confirma H2.

Tabla 8

Region	Años de salario
North East	6,2
North West	6,7
Wales	6,8
Yorkshire and The Humber	7,0

East Midlands	7,8
West Midlands	8,0
South West	10,2
East of England	10,7
South East	11,6
London	14,2

Nota. Precio mediana / salario joven regional, promedio 2015-2020.

Esfuerzo hipotecario 2022

La tabla 9 muestra la cuota mensual estimada para la vivienda mediana de 2022 y su porcentaje sobre el salario joven mensual, con la tasa winsorizada de 6,04 %. En las 10 regiones el esfuerzo supera el umbral del 30 % (del 43,0 % al 100,0 %); en London la cuota equivale al salario mensual completo. Se confirma H1: la hipoteca bloquea el acceso de los jóvenes.

Tabla 9

Region	Cuota mensual	% del salario	Dentro del 30 %
North East	GBP 772	43,0 %	no
North West	GBP 1.002	52,1 %	no
Yorkshire and The Humber	GBP 977	52,5 %	no
Wales	GBP 1.028	54,0 %	no
West Midlands	GBP 1.207	62,8 %	no
East Midlands	GBP 1.233	63,4 %	no
South West	GBP 1.589	79,1 %	no
East of England	GBP 1.745	81,8 %	no

South East	GBP 1.937	86,5 %	no
London	GBP 2.641	100,0 %	no

Nota. PMT, 90 % LTV, 25 anos, precio deflactado a GBP-2020.

Clima y precios

La tabla 10 reporta la correlacion de Pearson entre la variacion anual del precio y las anomalias climaticas regionales (n = 50 observaciones). La asociacion es debil y negativa ($|r| < 0,4$): el clima no explica los niveles de precio por region y su efecto es marginal (H3 con evidencia debil).

Tabla 10

Variable climatica	Pearson
Lluvia (anomalía)	-0,241
Temperatura maxima	-0,388
Temperatura minima	-0,399
Heladas (af)	-0,145
Sol	+0,238

Nota. Variacion anual del precio vs anomalía frente a la normal 1931-2020.

La anomalía se calculo restando a cada mes su promedio historico de la normal 1931-2020 y la variacion anual del precio como el cambio de la mediana regional de un año a otro, como muestra el fragmento de transformaciones.py:

```
# Anomalías climáticas (F3) - script/proyecto/transformaciones.py
normal = anual.groupby("estacion", observed=True)[
    ["tmax", "tmin", "lluvia", "sol", "af"]].transform("mean")
for col in ["tmax", "tmin", "lluvia", "sol", "af"]:
    anomalias[col + "_anom"] = anomalias[col] - normal[col]
regional = anomalias.groupby(["anio", "region"])[
    ["tmax_anom", "tmin_anom", "lluvia_anom", "sol_anom", "af_anom"]].mean()
```

Discusion y limitaciones

Los resultados apuntan a que la accesibilidad la definen el salario y la hipoteca, no el clima; aun asi, hay que leerlos con cuidado por tres razones. El salario mediano es nacional y se regionalizo con factores de referencia aproximados; las transacciones no informan la edad del comprador, de modo que el analisis es ecologico (region-ano) y no individual; y las hipotecas son un corte de 2022 que se proyecta a toda la serie. Las decisiones de depuracion quedaron registradas en la bitacora para poder repetirlas y revisarlas.

Trabajo futuro (fase 4)

Este documento es un avance progresivo: la fase 3 deja el cuadro maestro verificado (60 filas sin huecos en precio y salario) y un metodo de calidad de datos (MCAR/MAR/MNAR e IQR frente a z-score) aplicado a todas las fuentes. La siguiente fase (modelado) trabajara sobre la serie regional de precios y salarios para pronosticar la evolucion de la accesibilidad, y este informe continuara creciendo con los resultados de esas fases.

Referencias

- American Psychological Association. (2020). Publication manual of the American Psychological Association (7.^a ed.). <https://doi.org/10.1037/0000165-000>
- Bank of England. (2023). Consumer price inflation (CPI) series.
<https://www.bankofengland.co.uk>
- Fayyad, U., Piatetsky-Shapiro, G., & Smyth, P. (1996). From data mining to knowledge discovery in databases. *AI Magazine*, 17(3), 37-54.
<https://doi.org/10.1609/aimag.v17i3.1230>
- Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3.^a ed.). Morgan Kaufmann.
- HM Land Registry. (2026). Price paid data. GOV.UK.
<https://www.gov.uk/government/statistical-data-sets/price-paid-data-downloads>
- Kaggle. (2020). UK median house prices and salary 1975-2020 [Conjunto de datos].
<https://www.kaggle.com/datasets/samueltcortinhas/uk-median-house-prices-and-salary-19752020>
- Kaggle. (2020). UK Met Office weather data [Conjunto de datos].
<https://www.kaggle.com/datasets/josephw20/uk-met-office-weather-data>
- Kaggle. (2022). UK mortgage rates: Thousands of mortgage products [Conjunto de datos].
<https://www.kaggle.com/datasets/thedevastator/uk-mortgage-rates-thousands-of-mortgage-products>
- Kaggle. (2026). UK property sale prices 2015-2026 geo-enriched [Conjunto de datos].
<https://www.kaggle.com/datasets/mansiaggarwal88/uk-property-sale-prices-20152026-geo-enriched>

Little, R. J. A., & Rubin, D. B. (2019). Statistical analysis with missing data (3.^a ed.). Wiley.

Met Office. (s. f.). Historic station data. <https://www.metoffice.gov.uk/research/climate/maps-and-data/historic-station-data>

Office for National Statistics. (2022). Annual survey of hours and earnings: Reference table 2021. <https://www.ons.gov.uk>

SAS Institute. (s. f.). What is SEMMA? SAS Insights. <https://www.sas.com>

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En N. R. Berthold (Ed.), *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining* (pp. 29-39). Springer.